

Sistema de Recuperação Rápida de Informações em Protocolos de Saúde do SUS

Relatório de Detalhamento — Rumo ao TRL 1

Antônio Moreira Pinto, Celso Sacramento, João Pedro Porto Campos,
Laura Gonzaga, Leonardo Sá Silveira Lima, Thiago Rocha
INF2921 / CIS2114 — PUC-Rio
Maio de 2026

Resumo—Profissionais de saúde do SUS perdem tempo precioso buscando informações em protocolos clínicos distribuídos em PDFs fragmentados e sem indexação adequada. Este relatório detalha a proposta do Grupo E: um assistente conversacional baseado em *Retrieval-Augmented Generation* (RAG) que permite consultar protocolos em linguagem natural com respostas fundamentadas nas fontes oficiais. São apresentados dois casos de uso, além dos requisitos funcionais e não funcionais iniciais do sistema.

I. INTRODUÇÃO

O Sistema Único de Saúde (SUS) é operado por uma ampla rede de profissionais que dependem de protocolos clínicos padronizados para a tomada de decisão. Esses protocolos são distribuídos majoritariamente em formato PDF, resultando em uma base documental fragmentada e de difícil consulta durante o atendimento. A dificuldade de acesso rápido a essas informações impacta diretamente a qualidade e a velocidade do cuidado prestado ao paciente.

Este relatório apresenta o detalhamento inicial de um assistente conversacional baseado em *Retrieval-Augmented Generation* (RAG) voltado a profissionais do SUS. As seções seguintes discutem as soluções existentes (Seção II), a arquitetura proposta (Seção III), os requisitos iniciais (Seção IV) e os casos de uso ilustrativos (Seção V).

II. CONTEXTO E SOLUÇÕES EXISTENTES

Os Guias de Referência Rápida elaborados pelo Ministério da Saúde e pelas Secretarias Municipais compilam critérios diagnósticos, fluxos de atendimento e condutas terapêuticas [1]. Entretanto, cada guia pode conter dezenas de páginas disponíveis apenas em cópias físicas ou PDFs não indexados. Complementarmente, o *Data Zoom Saúde* disponibiliza microdados estruturados do DATASUS que podem enriquecer respostas sobre indicadores e disponibilidade de recursos [2].

As soluções existentes apresentam limitações relevantes. O *UpToDate* possui custo de licenciamento elevado e cobertura limitada de protocolos do contexto brasileiro. O *Telessaúde* não oferece interface conversacional e depende de consulta humana assíncrona. Já os LLMs de uso geral não garantem rastreabilidade até as fontes oficiais, gerando risco de respostas desatualizadas ou incorretas [3].

A oportunidade identificada é combinar acesso conversacional com fundamentação em documentos oficiais do SUS e integração com dados estruturados, lacuna que o sistema proposto pretende preencher.

III. SISTEMA PROPOSTO

A. Visão Geral

A solução é composta por três componentes integrados. O primeiro realiza a extração e indexação dos Guias de Referência Rápida em uma base vetorial, enriquecendo cada fragmento com metadados de origem. O segundo conecta o sistema ao *Data Zoom Saúde* para recuperação de indicadores epidemiológicos estruturados. O terceiro é a interface conversacional propriamente dita, que recebe perguntas em linguagem natural, recupera os fragmentos mais relevantes e gera respostas contextualizadas por meio de um LLM, citando as fontes consultadas. A Figura 1 ilustra uma interação típica com o sistema na interface idealizada.

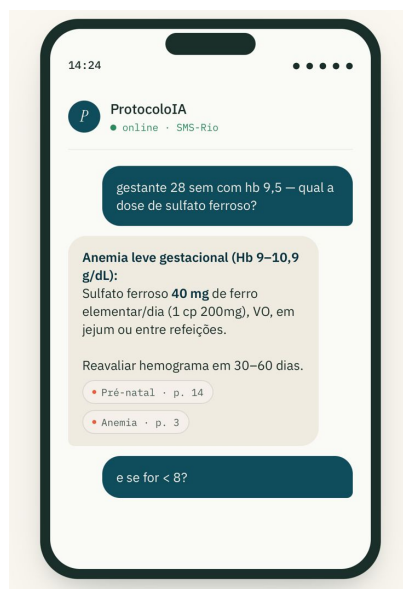


Figura 1. Mockup da interface conversacional do ProtocoloIA.

Tabela I
REQUISITOS FUNCIONAIS DO SISTEMA.

ID	Prior.	Descrição
RF01	Alta	Aceitar perguntas em português em linguagem natural, sem exigir conhecimento de sintaxe de busca.
RF02	Alta	Recuperar trechos relevantes de PDFs indexados por meio de busca semântica baseada em similaridade vetorial.
RF03	Alta	Gerar respostas fundamentadas nos documentos recuperados, citando o documento, seção e página de origem.
RF04	Alta	Suportar múltiplos documentos PDF simultaneamente na base vetorial, com atualização incremental.
RF05	Alta	Manter contexto de conversação em sessões curtas, permitindo perguntas de acompanhamento sem repetição.
RF06	Média	Integrar indicadores estruturados do <i>Data Zoom Saúde</i> para enriquecer respostas com dados epidemiológicos.
RF07	Média	Exibir o trecho original do documento ao qual a resposta se refere, possibilitando verificação pela fonte.
RF08	Média	Indicar nível de confiabilidade da resposta com base na relevância dos fragmentos recuperados.
RF09	Baixa	Permitir filtragem de consultas por categoria de protocolo (ex.: imunização, saúde mental, hipertensão).
RF10	Baixa	Oferecer suporte a consultas por voz, convertendo fala em texto antes do processamento.

Tabela II
REQUISITOS NÃO FUNCIONAIS DO SISTEMA.

ID	Categoria	Descrição
RNF01	Usabilidade	Interface acessível via browser sem instalação adicional, adequada a profissionais sem formação técnica.
RNF02	Rastreabilidade	Toda resposta deve citar o documento fonte, seção e página, permitindo verificação e auditoria posterior.
RNF03	Segurança	Dados clínicos identificáveis do paciente não devem ser incluídos nas consultas enviadas ao LLM nem nos logs.
RNF04	Confiabilidade	O sistema deve indicar explicitamente quando não há informação suficiente nos documentos indexados.
RNF05	Escalabilidade	A arquitetura deve suportar a inclusão de novos documentos sem reprocessamento total da base vetorial.
RNF06	Conformidade	O sistema deve aderir à LGPD no tratamento de dados de acesso e de identificação de usuários.
RNF07	Manutenibilidade	Os documentos indexados devem poder ser atualizados independentemente, refletindo novas versões dos protocolos.

B. Fontes de Dados

O sistema opera sobre duas fontes complementares. Os Guias de Referência Rápida (dado não estruturado) são documentos PDF produzidos pelo Ministério da Saúde e Secretarias Municipais, contendo fluxos clínicos e condutas terapêuticas. O *Data Zoom Saúde* (dado estruturado) oferece microdados do DATASUS (SIH, SIA, SINAN) sobre produção ambulatorial, internações e epidemiologia por município.

C. Arquitetura de Recuperação

O fluxo de consulta segue o padrão RAG [4]: a pergunta do usuário é codificada em um vetor $\mathbf{q}$ e cada fragmento indexado em um vetor $\mathbf{d}$, ambos produzidos por um modelo de recuperação densa [5]. Os k fragmentos de maior similaridade do cosseno,

$$\text{sim}(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|}, \quad (1)$$

são concatenados ao prompt enviado ao LLM, que formula a resposta final com referências explícitas às fontes consultadas.

IV. REQUISITOS DO SISTEMA

A Tabela I classifica os requisitos funcionais por prioridade: alta prioridade compõe o núcleo do MVP a ser validado na primeira iteração; média prioridade agrega valor sem bloquear essa validação; baixa prioridade fica reservada para versões subsequentes. A Tabela II organiza os requisitos não funcionais por categoria de qualidade. Rastreabilidade e segurança recebem atenção especial em razão das implicações clínicas do domínio e da obrigação de conformidade com a LGPD.

V. CASOS DE USO

A. Caso de Uso 1: Consulta de Protocolo Clínico

Um médico da Atenção Primária, durante uma consulta, questiona o sistema sobre o protocolo de tratamento para hipertensão arterial sistêmica sem comorbidades. O assistente recupera os trechos pertinentes do Guia de Referência Rápida da SMS e apresenta a conduta recomendada com indicação da página e versão do documento, sem que o profissional precise interromper o atendimento para abrir o PDF manualmente.

B. Caso de Uso 2: Consulta do Calendário de Vacinação

Uma enfermeira de UBS precisa confirmar o esquema vacinal para uma criança de 15 meses que chegou sem cartão de vacinação. Ao descrever a situação ao assistente, recebe uma lista estruturada das vacinas indicadas pelo Programa Nacional de Imunizações (PNI), com doses, vias de administração e intervalos mínimos, referenciada à versão vigente do calendário oficial.

VI. PRÓXIMAS ETAPAS

O presente relatório situa o projeto no TRL 1, com a proposta conceitual formalizada em requisitos e casos de uso. As etapas previstas são:

- Protótipo de recuperação** (TRL 2): indexação de um subconjunto dos Guias de Referência Rápida em uma base vetorial local e avaliação qualitativa da relevância dos fragmentos recuperados.
- Validação com usuários** (TRL 3): sessões de uso com profissionais de saúde para aferir usabilidade e correteude percebida das respostas geradas.

REFERÊNCIAS

- [1] Ministério da Saúde, “Guias de referência rápida da atenção primária à saúde,” <https://www.gov.br/saude>, 2023, acessado em: maio 2026.
- [2] Data Zoom Saúde – PUC-Rio, “Microdados do DATASUS harmonizados,” <https://www.econ.puc-rio.br/datazoom/saude>, 2024, acessado em: maio 2026.
- [3] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, and H. Wang, “Retrieval-augmented generation for large language models: A survey,” *arXiv preprint arXiv:2312.10997*, 2023.
- [4] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [5] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, “Dense passage retrieval for open-domain question answering,” in *Proceedings of EMNLP*, 2020, pp. 6769–6781.