

# Sistema de Recuperação Rápida de Informações em Protocolos de Saúde do SUS

Relatório de Detalhamento — Rumo ao TRL 1

Antônio Moreira Pinto, Celso Sacramento, João Pedro Porto Campos,  
Laura Gonzaga, Leonardo Sá Silveira Lima, Thiago Rocha  
INF2921 / CIS2114 — PUC-Rio  
Maio de 2026

**Resumo**—Profissionais de saúde do SUS perdem tempo precioso buscando informações em protocolos clínicos distribuídos em PDFs fragmentados e sem indexação adequada. Este relatório detalha a proposta do Grupo E: um assistente conversacional baseado em *Retrieval-Augmented Generation* (RAG) que permite consultar protocolos em linguagem natural com respostas fundamentadas nas fontes oficiais. São apresentados dois casos de uso, além dos requisitos funcionais e não funcionais iniciais do sistema.

## I. INTRODUÇÃO

O Sistema Único de Saúde (SUS) é operado por uma ampla rede de profissionais que dependem de protocolos clínicos padronizados para a tomada de decisão. Esses protocolos são distribuídos majoritariamente em formato PDF, resultando em uma base documental fragmentada e de difícil consulta durante o atendimento. A dificuldade de acesso rápido a essas informações impacta diretamente a qualidade e a velocidade do cuidado prestado ao paciente.

Este relatório apresenta o detalhamento inicial de um assistente conversacional baseado em *Retrieval-Augmented Generation* (RAG) voltado a profissionais do SUS. As seções seguintes discutem as soluções existentes (Seção II), a arquitetura proposta (Seção III), os requisitos iniciais (Seção IV) e os casos de uso ilustrativos (Seção V).

## II. CONTEXTO E SOLUÇÕES EXISTENTES

Os Guias de Referência Rápida elaborados pelo Ministério da Saúde e pelas Secretarias Municipais compilam critérios diagnósticos, fluxos de atendimento e condutas terapêuticas [1]. Entretanto, cada guia pode conter dezenas de páginas disponíveis apenas em cópias físicas ou PDFs não indexados. Complementarmente, o *Data Zoom Saúde* disponibiliza microdados estruturados do DATASUS que podem enriquecer respostas sobre indicadores e disponibilidade de recursos [2].

As soluções existentes apresentam limitações relevantes. O *UpToDate* possui custo de licenciamento elevado e cobertura limitada de protocolos do contexto brasileiro. O *Telessaúde* não oferece interface conversacional e depende de consulta humana assíncrona. Já os LLMs de uso geral não garantem rastreabilidade até as fontes oficiais, gerando risco de respostas desatualizadas ou incorretas [3].

A oportunidade identificada é combinar acesso conversacional com fundamentação em documentos oficiais do SUS e integração com dados estruturados, lacuna que o sistema proposto pretende preencher.

## III. SISTEMA PROPOSTO

### A. Visão Geral

A solução é composta por três componentes integrados. O primeiro realiza a extração e indexação dos Guias de Referência Rápida em uma base vetorial, enriquecendo cada fragmento com metadados de origem. O segundo conecta o sistema ao *Data Zoom Saúde* para recuperação de indicadores epidemiológicos estruturados. O terceiro é a interface conversacional propriamente dita, que recebe perguntas em linguagem natural, recupera os fragmentos mais relevantes e gera respostas contextualizadas por meio de um LLM, citando as fontes consultadas. A Figura 1 ilustra uma interação típica com o sistema na interface idealizada.




Figura 1. Mockup da interface conversacional do ProtocoloIA.

Tabela I  
REQUISITOS FUNCIONAIS DO SISTEMA.

| ID   | Prior. | Descrição                                                                                                        |
|------|--------|------------------------------------------------------------------------------------------------------------------|
| RF01 | Alta   | Aceitar perguntas em português em linguagem natural, sem exigir conhecimento de sintaxe de busca.                |
| RF02 | Alta   | Recuperar trechos relevantes de PDFs indexados por meio de busca semântica baseada em similaridade vetorial.     |
| RF03 | Alta   | Gerar respostas fundamentadas nos documentos recuperados, citando o documento, seção e página de origem.         |
| RF04 | Alta   | Suportar múltiplos documentos PDF simultaneamente na base vetorial, com atualização incremental.                 |
| RF05 | Alta   | Manter contexto de conversação em sessões curtas, permitindo perguntas de acompanhamento sem repetição.          |
| RF06 | Média  | Integrar indicadores estruturados do <i>Data Zoom Saúde</i> para enriquecer respostas com dados epidemiológicos. |
| RF07 | Média  | Exibir o trecho original do documento ao qual a resposta se refere, possibilitando verificação pela fonte.       |
| RF08 | Média  | Indicar nível de confiabilidade da resposta com base na relevância dos fragmentos recuperados.                   |
| RF09 | Baixa  | Permitir filtragem de consultas por categoria de protocolo (ex.: imunização, saúde mental, hipertensão).         |
| RF10 | Baixa  | Oferecer suporte a consultas por voz, convertendo fala em texto antes do processamento.                          |

Tabela II  
REQUISITOS NÃO FUNCIONAIS DO SISTEMA.

| ID    | Categoria        | Descrição                                                                                                       |
|-------|------------------|-----------------------------------------------------------------------------------------------------------------|
| RNF01 | Usabilidade      | Interface acessível via browser sem instalação adicional, adequada a profissionais sem formação técnica.        |
| RNF02 | Rastreabilidade  | Toda resposta deve citar o documento fonte, seção e página, permitindo verificação e auditoria posterior.       |
| RNF03 | Segurança        | Dados clínicos identificáveis do paciente não devem ser incluídos nas consultas enviadas ao LLM nem nos logs.   |
| RNF04 | Confiabilidade   | O sistema deve indicar explicitamente quando não há informação suficiente nos documentos indexados.             |
| RNF05 | Escalabilidade   | A arquitetura deve suportar a inclusão de novos documentos sem reprocessamento total da base vetorial.          |
| RNF06 | Conformidade     | O sistema deve aderir à LGPD no tratamento de dados de acesso e de identificação de usuários.                   |
| RNF07 | Manutenibilidade | Os documentos indexados devem poder ser atualizados independentemente, refletindo novas versões dos protocolos. |

## B. Fontes de Dados

O sistema opera sobre duas fontes complementares. Os Guias de Referência Rápida (dado não estruturado) são documentos PDF produzidos pelo Ministério da Saúde e Secretarias Municipais, contendo fluxos clínicos e condutas terapêuticas. O *Data Zoom Saúde* (dado estruturado) oferece microdados do DATASUS (SIH, SIA, SINAN) sobre produção ambulatorial, internações e epidemiologia por município.

## C. Arquitetura de Recuperação

O fluxo de consulta segue o padrão RAG [4]: a pergunta do usuário é codificada em um vetor  $\mathbf{q}$  e cada fragmento indexado em um vetor  $\mathbf{d}$ , ambos produzidos por um modelo de recuperação densa [5]. Os  $k$  fragmentos de maior similaridade do cosseno,

$$\text{sim}(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|}, \quad (1)$$

são concatenados ao prompt enviado ao LLM, que formula a resposta final com referências explícitas às fontes consultadas.

## IV. REQUISITOS DO SISTEMA

A Tabela I classifica os requisitos funcionais por prioridade: alta prioridade compõe o núcleo do MVP a ser validado na primeira iteração; média prioridade agrega valor sem bloquear essa validação; baixa prioridade fica reservada para versões subsequentes. A Tabela II organiza os requisitos não funcionais por categoria de qualidade. Rastreabilidade e segurança recebem atenção especial em razão das implicações clínicas do domínio e da obrigação de conformidade com a LGPD.

## V. CASOS DE USO

### A. Caso de Uso 1: Consulta de Protocolo Clínico

Um médico da Atenção Primária, durante uma consulta, questiona o sistema sobre o protocolo de tratamento para hipertensão arterial sistêmica sem comorbidades. O assistente recupera os trechos pertinentes do Guia de Referência Rápida da SMS e apresenta a conduta recomendada com indicação da página e versão do documento, sem que o profissional precise interromper o atendimento para abrir o PDF manualmente.

### B. Caso de Uso 2: Consulta do Calendário de Vacinação

Uma enfermeira de UBS precisa confirmar o esquema vacinal para uma criança de 15 meses que chegou sem cartão de vacinação. Ao descrever a situação ao assistente, recebe uma lista estruturada das vacinas indicadas pelo Programa Nacional de Imunizações (PNI), com doses, vias de administração e intervalos mínimos, referenciada à versão vigente do calendário oficial.

## VI. PRÓXIMAS ETAPAS

O presente relatório situa o projeto no TRL 1, com a proposta conceitual formalizada em requisitos e casos de uso. As etapas previstas são:

- Protótipo de recuperação** (TRL 2): indexação de um subconjunto dos Guias de Referência Rápida em uma base vetorial local e avaliação qualitativa da relevância dos fragmentos recuperados.
- Validação com usuários** (TRL 3): sessões de uso com profissionais de saúde para aferir usabilidade e correteude percebida das respostas geradas.

## REFERÊNCIAS

- [1] Ministério da Saúde, “Guias de referência rápida da atenção primária à saúde,” <https://www.gov.br/saude>, 2023, acessado em: maio 2026.
- [2] Data Zoom Saúde – PUC-Rio, “Microdados do DATASUS harmonizados,” <https://www.econ.puc-rio.br/datazoom/saude>, 2024, acessado em: maio 2026.
- [3] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, and H. Wang, “Retrieval-augmented generation for large language models: A survey,” *arXiv preprint arXiv:2312.10997*, 2023.
- [4] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [5] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, “Dense passage retrieval for open-domain question answering,” in *Proceedings of EMNLP*, 2020, pp. 6769–6781.